

STAT

Lageparameter

Arithmetisches Mittel ("Durchschnitt") / `.mean()`: $\bar{x} = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$ \nearrow mean sagt nichts über die Streuung der Daten aus
 \hookrightarrow Mittelwert

Median ("Mitte") = Daten sortieren \nearrow Bei gerader Anzahl: `mean()` von den mittleren zwei
 \hookrightarrow Vorteil: Robustheit bei extremen Beobachtungen \nearrow Bei ungerader Anzahl: der Wert in der Mitte
 Trick: `k = np.round(0.5 * n + 0.5) - 1` pandas: `median()`

Quantile
 Unteres Quartil: Wert, wo 25% kleiner oder gleich und 75% grösser oder gleich sind
 Oberes Quartil: Wert, wo 75% kleiner oder gleich und 25% grösser oder gleich sind
`xxx.quantile(q=[.25, .75], interpolation="midpoint") = q75, q25 = xxx.quantile(q=[.75, .25], interpolation="midpoint")`


Streuungsparameter:

\nearrow Pandas \Rightarrow `.var()` \nearrow Pandas \Rightarrow `.std()`
 Empirische Varianz / Empirische Standardabweichung \nearrow Durch $\sqrt{\quad}$ kommen die Daten wieder in dieselbe Einheit.

$$Var(x) = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s_x = \sqrt{Var(x)} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

• $Var(x)$ & s_x gross \Rightarrow so ist die Streuung der Messwerte gross. (+ \bar{x})

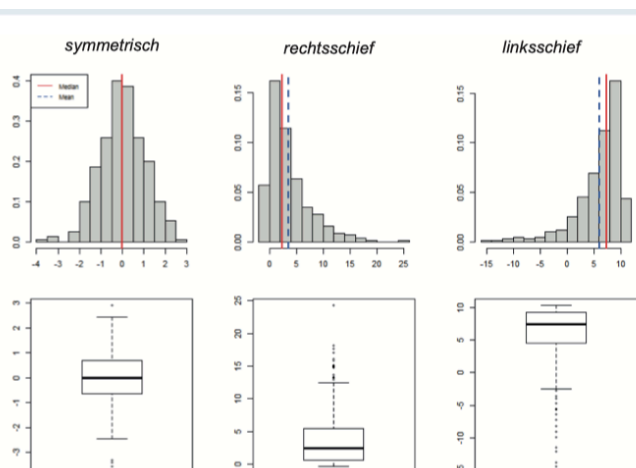


Quartilsdifferenz: oberes Quartil - unteres Quartil



Graphische Darstellung

Histogramm: Aufteilung in n-Klassen (Intervall) $\begin{cases} < 50 \text{ Messungen} = \text{Klasse 5 bis 7} \\ > 250 \text{ Messungen} = \text{Klasse 10 bis 20} \end{cases}$


Boxplot



Schiefe von Daten
 $\mu = \text{Median}$
 $\mu = \text{Mean}$

Lineare Regression

Residuum: Abstand der Messpunkte zur Regressionsgerade. $r_i = y_i - a - bx_i$



$$t = \sum_{i=1}^n (r_i)^2$$

$a+b$ von linearer Regression

$$b = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$a = \bar{y} - b\bar{x}$$

Empirische Korrelation

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{(\sum_{i=1}^n (x_i - \bar{x})^2) \cdot (\sum_{i=1}^n (y_i - \bar{y})^2)}}$$

Numerische Zusammenfassung der lin. Abhängigkeiten von zwei Größen.

eine Zahl $r \Rightarrow [-1; 1]$

$r = +1 \Rightarrow$ dann liegen Punkte auf steigender Geraden $b > 0$

$r = -1 \Rightarrow$ dann liegen Punkte auf fallender Geraden $b < 0$

$r = 0 \Rightarrow$ x und y unabhängig
keinen Zusammenhang

Stetige W'keitsverteilung

Jass bsw: $\omega = As \Rightarrow X(\omega) = 11 \Rightarrow x = 11$



Zufallsvariable X ist eine Funktion (kann auch Y, Z sein)

Elementarereignis ω

Zahlenwert / konkreten Wert: x (x eine Realisierung der Zufallsvariable (X))

Grundraum Ω

diskret (endlich abzählbare Menge)



Die Werte einer Zufallsvariablen X (die möglichen Realisationen von X) treten mit gewissen Wahrscheinlichkeiten auf. Die Wahrscheinlichkeit, dass X den Wert x annimmt, berechnet sich wie folgt:

$$P(X = x) = P(\{\omega \mid X(\omega) = x\}) = \sum_{\omega: X(\omega) = x} P(\omega)$$


W'keit von allen Realisierungen \Rightarrow W'keitsverteilung

$$\sum P(X = x) \Rightarrow 1$$

Eigenschaften Wahrscheinlichkeitsdichte

- 1 $f(x) \geq 0$ für alle x (da $F(\cdot)$ monoton wachsend ist)
- 2 $P(a < X \leq b) = F(b) - F(a) = \int_a^b f(x) dx$ (Fläche zwischen a und b unter $f(x)$)
- 3 $\int_{-\infty}^{\infty} f(x) dx = 1$ (wegen 2.)

W'keit unter dem gesamten Intervall = 1



Erwartungswert: $E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$

Varianz: $\text{Var}(X) = \sigma_x^2 = E(X^2) - E(X)^2$

Kumulative Verteilung: $P(X \leq x) \Rightarrow \text{cdf}$