

Vorzeichentest Wilcoxontest Mann-Whitney-Test

Peter Büchel

HSLU I

Stat: Block 08

Nicht-Normalverteilte Daten: Vorzeichentest

1. Modell:

$$X_1, \dots, X_n \text{ iid}$$

wobei X_i eine beliebige Verteilung hat

2. Nullhypothese:

$$H_0 : \mu = \mu_0 \quad (\mu \text{ Median})$$

Alternative:

$$H_A : \mu \neq \mu_0 \quad (\text{oder einseitige Variante})$$

3. Teststatistik:

$$V: \text{Anzahl } X_i\text{'s mit } (X_i > \mu_0)$$

Verteilung der Teststatistik unter H_0 :

$$V \sim \text{Bin}(n, \pi_0) \quad \text{mit } \pi_0 = 0.5$$

4. *Signifikanzniveau:*

$$\alpha$$

5. *Verwerfungsbereich für die Teststatistik:*

$$K = [0, c_u] \cup [c_o, n]$$

falls $H_A : \mu \neq \mu_0$.

Grenzen c_u und c_o müssen mit Binomialverteilung oder Normalapproximation berechnet werden

6. *Testentscheid:* Entscheide, ob der beobachtete Wert der Teststatistik im Verwerfungsbereich der Teststatistik liegt

Beispiel: Vorzeichentest

- Beobachtet:

$$x_1 = 13, \quad x_2 = 9, \quad x_3 = 17, \quad x_4 = 8, \quad x_5 = 14$$

- Angenommen:

$$H_0 : \mu = \mu_0 = 10, \quad H_A : \mu \neq 10$$

- Vorzeichen von $x_i - \mu_0$:

$$+, -, +, -, +$$

- Binomialtest mit

$$H_0 : \pi = 0.5, \quad H_A : \pi \neq 0.5, \quad n = 5, \quad x = 3 \text{ (Anzahl „+“)}$$

Beispiel: Vorzeichentest

- Antwort: Binomialtest mit **Python**

```
import scipy.stats as st

st.binom_test(x=3, n=5, p=0.5)


## 1.0
```

- Resultat ist P -Wert
- Nullhypothese beim Vorzeichentest wird nicht verworfen
- **Vorteil vom Vorzeichentest:** Keine Annahme an Verteilung
- **Nachteil vom Vorzeichentest:** Kleinere Macht

Nicht-normalverteilte Daten: Wilcoxon-Test

- Kompromiss zwischen Vorzeichen- und t -Test
- Annahme:

$X_i \sim F$ iid, F ist symmetrisch



- Teste Median μ : $H_0 : \mu = \mu_0$ (einseitig oder zweiseitig)
- Intuition der Teststatistik
 - ▶ Rangiere
$$|x_i - \mu_0| \rightarrow r_i$$
 - ▶ Gib Rängen ursprüngliches Vorzeichen von $(x_i - \mu_0)$ ("signed ranks")
 - ▶ Teststatistik T : Summe aller Ränge, bei denen $(x_i - \mu_0)$ positiv ist
- Falls H_0 stimmt, sollte Rangsumme nicht zu gross und nicht zu klein sein

Beispiel: Wilcoxon-Test

- Bsp: $H_0 : \mu_0 = 0$

- Beobachte:

-1.9, 0.2, 2.9, -4.1, 3.9

- Absolutbeträge:

1.9, 0.2, 2.9, 4.1, 3.9

- Geordnet

0.2, 1.9, 2.9, 3.9, 4.1

- Ränge der Absolutbeträge:

1, 2, 3, 4, 5

- Rangsumme der positiven Gruppe: $1+3+4=8$

- ▶ Minimale Rangsumme: 0

- ▶ Maximale Rangsumme: $1+2+3+4+5 = 15$

Wicoxon-Test mit Python

- Code

```
import scipy.stats as st
import numpy as np

x = np.array([-1.9, 0.2, 2.9, -4.1, 3.9])

st.wilcoxon(x, correction=True)

## /home/bl/.local/lib/python3.6/site-packages/scipy/stats/morestats.py
##   warnings.warn("Warning: sample size too small for normal approximation")
## WilcoxonResult(statistic=7.0, pvalue=1.0)
```

Übersicht der Tests

Test	Annahme				n_{\min} bei $\alpha = 0.05$	Macht für ein Beispiel (1)
	σ_X bekannt	$X_i \sim N$	Symm. Verteilung	iid		
z	x	x	x	x	1	89 %
t		x	x	x	2	79 %
Wilcoxon			x	x	6	79 %
VZ				x	5	48 %

(1): $X_i \sim \mathcal{N}(\mu, \sigma^2)$, $n = 10$; $H_0 : \mu = 0$; $H_A : \mu \neq 0$; $\alpha = 0.05$

Macht berechnet für konkrete Alternative: $X_i \sim \mathcal{N}(1, 1)$

Wilcoxon-Test versus t-Test

- *Wilcoxon-Test* meistens *t-Test* oder *Vorzeichen-Test* vorzuziehen
- Er hat in vielen Situationen oftmals wesentlich *grössere Macht*, und selbst in den ungünstigsten Fällen ist er nie viel schlechter
- Wenn man trotzdem den *t-Test* verwendet, dann sollte man die Daten auch graphisch ansehen, damit wenigstens grobe Abweichungen von der Normalverteilung entdeckt werden
- Insbesondere sollte der *Normal-Plot* angeschaut werden

Vergleich von zwei Stichproben

- Mögliche Fragestellungen:
 - ▶ Vergleich von zwei Messverfahren (Messgerät A vs. Messgerät B): Gibt es einen signifikanten Unterschied?
 - ▶ Vergleich von zwei Herstellungsverfahren (A vs. B): Welches hat die besseren Eigenschaften (z.B. bzgl. einer Festigkeitsgrösse)?
 - ▶ Werden männliche Dozenten von weiblichen Studierenden besser als von männlichen Studierenden bewertet?
 - ▶ Sammeln jeweils Daten von zwei Gruppen

Gepaarte Stichproben

- Beispiel Messgeräte: Jeden Prüfkörper mit *beiden* Messgeräten messen
- Pro *Versuchseinheit* (hier: Prüfkörper) zwei Beobachtungen (einmal Gerät *A* und einmal Gerät *B*)
- Man spricht auch von *gepaarten Stichproben*
- Beide Beobachtungen sind *nicht* unabhängig, da an der *gleichen* Versuchseinheit zwei Mal gemessen wird!


Ungepaarte (unabhängige) Stichproben

- Beispiel der beiden Herstellungsverfahren: Stichprobe von Verfahren A und eine andere Stichprobe von Verfahren B
- Beobachtungen sind hier *unabhängig*; "es gibt *nichts*, was sie verbindet"
- Man spricht von *ungepaarten (oder unabhängigen) Stichproben*

Unterscheidung gepaart versus ungepaarte Stichproben


Gepaarte Stichproben

- Jede Beobachtung einer Gruppe kann eindeutig einer Beobachtung der anderen Gruppe zugeordnet werden
- Stichprobengröße ist in beiden Gruppen zwangsläufig gleich




Ungepaarte Stichproben

- Keine Zuordnung von Beobachtungen möglich
- Stichprobengrößen können verschieden sein (müssen aber nicht!)
- Man kann die eine Gruppe vergrößern, ohne dass man die andere vergrößert



Gepaarte versus ungepaarte Stichproben

- Beispiel Augeninnendruck: Ein Auge wird behandelt, das andere nicht (gepaarter Test ist angebracht)
- Gemäss Voraussetzungen dürfte auch ein ungepaarter Test angewendet werden



Ungepaart:

Intuition Teststatistik: $T = \frac{\bar{X} - \bar{Y}}{\widehat{\sigma_{\bar{X}}}}$

Gepaart:

Differenz $D_i = X_i - Y_i$

Teststatistik $T = \frac{\bar{D}}{\widehat{\sigma_D}}$

Statistischer Test für gepaarte Stichproben mit Python

- *Gepaarte Stichproben:*

$$X_i \sim \mathcal{N}(\mu_X, \sigma_X^2) \quad \text{und} \quad Y_i \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$$

- Betrachten Differenzen $D_i = X_i - Y_i$
- Führen einen t-Test durch mit der Teststatistik D_i
- Normalerweise Nullhypothese $E[D] = \mu_D = 0$, also kein Unterschied
- Falls die Daten nicht normalverteilt, dann kommt ein Wilcoxon- oder Vorzeichentest in Frage.

Statistischer Test für gepaarte Stichproben mit Python

- Code

```
import scipy.stats as st
from scipy.stats import norm, t, binom
import numpy as np
from pandas import Series

vorher = Series([25, 25, 27, 44, 30, 67, 53, 53, 52, 60, 28])

nachher = Series([27, 29, 37, 56, 46, 82, 57, 80, 61, 59, 43])

st.ttest_rel(nachher, vorher)

## Ttest_relResult(statistic=4.271608818429545, pvalue=0.0016328499219)
```

- P-Wert ist mit 0.0016 unter Signifikanzniveau und somit wird Nullhypothese verworfen

- Vertrauensintervall:

```
vorher = Series([25, 25, 27, 44, 30, 67, 53, 53, 52, 60, 28])
nachher = Series([27, 29, 37, 56, 46, 82, 57, 80, 61, 59, 43])
dif = nachher - vorher

t.interval(alpha=.95, df=dif.size-1, loc=dif.mean(),
scale=dif.std()/np.sqrt(dif.size))

## (4.91430993515407, 15.631144610300478)
```

- Unterschied auf 5 % Signifikanzniveau signifikant, weil P-Wert kleiner 5 %
- 95 %-Vertrauensintervall: Unterschieds in den Gruppenmittelwerten
- Mit 95 % W'keit ist Gruppenmittelwert von x um eine Zahl im Bereich

[4.91431, 15.63114]

grösser als der Gruppenmittelwert von y

Statistischer Test für ungepaarte Stichproben mit Python

- *Ungepaarte Stichproben*: Daten X_i und Y_i normalverteilt, aber ungepaart
- Beispiel: Schmelzwärme von Eis: Zwei-Stichproben t-Test für ungepaarte Stichproben mit Nullhypothese $\mu_X = \mu_Y$:

```
x = Series([79.98, 80.04, 80.02, 80.04, 80.03, 80.03, 80.04,
79.97, 80.05, 80.03, 80.02, 80.00, 80.02])

y = Series([80.02, 79.94, 79.98, 79.97, 80.03, 79.95, 79.97])

st.ttest_ind(x, y, equal_var=False)

## Ttest_indResult(statistic=2.839932638516127, pvalue=0.018660)
```

- P-Wert ist 0.018 unter dem Signifikanzniveau und somit wird die Nullhypothese verworfen.

- Unterschied auf 5 % Signifikanzniveau signifikant, weil P-Wert kleiner als 5 %
- Unterschied in den Gruppenmittelwerten

Mann-Whitney U-Test (aka Wilcoxon Rank-sum Test)

- Falls Daten nicht normalverteilt

- $X_i \sim F, i = 1, \dots, n; Y_j \sim G, j = 1, \dots, m$

$$H_0: F = G$$

$$H_A: F = G + \delta \ (\delta \neq 0) \text{ (oder einseitig)}$$

(d.h., Verteilungen sind verschoben, haben aber gleiche Form)

- Code

```
x = Series([79.98, 80.04, 80.02, 80.04, 80.03, 80.03, 80.04,
79.97, 80.05, 80.03, 80.02, 80.00, 80.02])

y = Series([80.02, 79.94, 79.98, 79.97, 80.03, 79.95, 79.97])

st.mannwhitneyu(x, y)

## MannwhitneyuResult(statistic=14.5, pvalue=0.0072688224723693)
```

- Nullhypothese wird verworfen

Übersicht: Tests für ungepaarte Stichproben

Test	Annahme				n_{\min} falls ($n = m$) bei $\alpha = 0.05$	Macht für ein Beispiel (1)
	$\sigma_X = \sigma_Y$	$X_i \sim N$ $Y_i \sim N$	F, G haben gleiche Form	iid pro Gruppe		
t ($\sigma_X = \sigma_Y$)	x	x	x	x	2	57%
t ($\sigma_X \neq \sigma_Y$)		x		x	2	56%
MW U-Test	x		x	x	4	53%

(1): $X_i \sim \mathcal{N}(\mu_X, \sigma^2)$, $Y_i \sim \mathcal{N}(\mu_Y, \sigma^2)$ $n = m = 10$; $H_0 : \mu_X = \mu_Y$; $H_A : \mu_X \neq \mu_Y$;
 $\alpha = 0.05$

Macht berechnet für konkrete Alternative: $X_i \sim \mathcal{N}(0, 1)$, $Y_i \sim \mathcal{N}(1, 1)$

Übersicht Statistische Tests (stetige Verteilungen)

